

# Chapter 3 : Single-Variate Linear Regression without Bias Term.

1-4. Loss and Cost Function 2.

Loss :  $\mathcal{L}^{(i)}(\theta) = (y^{(i)} - (\theta x^{(i)}))^2$

Weight of Feature values  
in vector


↑  
dot product

Degree of  $d=2$

→  $y$ 와  $x$ 의 2차 곱

Cost :  $J(\theta) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\theta x^{(i)}))^2$  여기서 Degree of  $d=2$

↓  
실제값과 예측값 사이 차이들의 제곱의 평균.



$$\hat{y} = \theta_1 x + \theta_0$$

→ Bias Term

선형모델에서 Bias Term이  
추가됨.

구미러

↓	Model :	$\hat{y} = \theta_1 x + \theta_0$
	Loss :	$\mathcal{L}^{(i)} = (y^{(i)} - \hat{y}^{(i)})^2$
	Cost :	$J = \frac{1}{n} \sum_{i=1}^n \mathcal{L}^{(i)}$

여기서 같다.

< Model  $\hat{y} = \theta_1 x + \theta_0$  이 모델 Loss 는 >

$$\mathcal{L}^{(i)} = (y^{(i)} - \hat{y}^{(i)})^2 \quad \hat{y} = \theta_1 x + \theta_0$$

$$\mathcal{L}^{(i)}(\underline{\theta}_1, \underline{\theta}_0) = (\underline{y}^{(i)} - (\underline{\theta}_1 x^{(i)} + \underline{\theta}_0))^2$$

이때,  $\vec{\theta} = \begin{pmatrix} \theta_1 \\ \theta_0 \end{pmatrix}$   $\vec{x}^{(i)} = \begin{pmatrix} x^{(i)} \\ 1 \end{pmatrix}$  이라고 하면

$$\mathcal{L}^{(i)}(\theta_1, \theta_0) = (y^{(i)} - (\vec{\theta}^T \vec{x}^{(i)}))^2 \quad \text{가 된다}$$

$$[\theta_1 \ \theta_0] \cdot \begin{bmatrix} x^{(i)} \\ 1 \end{bmatrix} = \theta_1 x^{(i)} + \theta_0$$

< Model  $\hat{y} = \theta_1 x + \theta_0$  이 모델 Cost 는 >

$$J = \frac{1}{n} \sum_{i=1}^n \mathcal{L}^{(i)}$$

$$J(\underline{\theta}_1, \underline{\theta}_0) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\underline{\theta}_1 x^{(i)} + \underline{\theta}_0))^2$$


이와 같은 이유로

$$J(\theta_1, \theta_0) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\vec{\theta}^T \vec{x}^{(i)}))^2$$

위에서 구한 식 
$$L^{(i)}(\theta_1, \theta_0) = (y^{(i)} - (\theta_1 x^{(i)} + \theta_0))^2$$

$$J(\theta_1, \theta_0) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\theta_1 x^{(i)} + \theta_0))^2$$
 둘 다 각각  $\theta_1$  이나  $\theta_0$  에 대해서 2차 함수인  
 2개의  $\theta_1$  와  $\theta_0$  의 계수 각각 양수이므로 아래 볼 것 ✓.

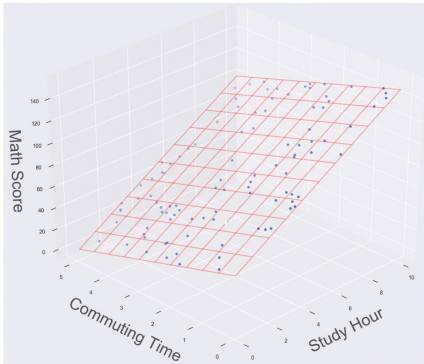
Cost function을  
3D로 보면...



gradient로  
가장 아래 점으로 가야 함.

위와 같은 factor, 특정인 경우 (x)  $\rightarrow$  학습시간 Computing time & Study hour 등의  
만약에를 변경으로 볼 것.

< Feature 두개 일때 2D로 >



학습  
Model : 
$$y = \theta_2 x_2 + \theta_1 x_1 + \theta_0$$

$$L^{(i)} = (y^{(i)} - \hat{y}^{(i)})^2$$
 큰 feature  
일수록 같다.

$$J = \frac{1}{n} \sum_{i=1}^n L^{(i)}$$

< feature 가 두개 일 때 Loss or Cost는 ... >

Loss : 
$$L^{(i)}(\theta_2, \theta_1, \theta_0) = (y^{(i)} - (\theta_2 x_2 + \theta_1 x_1 + \theta_0))^2$$

$$L^{(i)}(\vec{\theta}) = (y^{(i)} - (\vec{\theta}^T \cdot \vec{X}^{(i)}))^2$$

Cost : 
$$J(\vec{\theta}) = \frac{1}{n} \sum_{i=1}^n L^{(i)}(\vec{\theta})$$

이때는 Loss or Cost 모두 각각 Weight,  $\theta_1, \theta_2, \theta_0$  여 대해서  
2차 함수이다. (U shape)

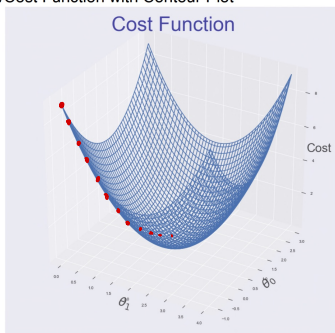
\* 변수 개수  $\rightarrow$  4차원이다 U 보임 (상당)

여기 구현된 Loss or Cost는 feature의 개수 상관없이.

$$\vec{\theta} = \begin{pmatrix} \theta_n \\ \theta_{n+1} \\ \vdots \\ \theta_1 \\ \theta_0 \end{pmatrix} \quad \vec{x} = \begin{pmatrix} x_n \\ x_{n+1} \\ \vdots \\ x_1 \\ x_0 \end{pmatrix} \quad \text{일때,}$$


$$\underline{L^{(i)}(\vec{\theta}) = (y^{(i)} - \vec{\theta}^T \vec{x}^{(i)})^2} \quad \underline{J(\vec{\theta}) = \frac{1}{n} \sum_{i=1}^n L^{(i)}(\vec{\theta})} \quad \text{이다.}$$

| Loss/Cost Function with Contour Plot




Contour Plot은 최적인 값에 대한  
더 쉽게 만듦.

Cost Function



각 점은 Cost 값은 커짐.

| Real Loss/Cost Functions



실제 Cost function은  $x_1, x_2$  같은 term도 가진다  
2개씩  $x_1, x_2$  가 커진수록 평면으로 점점 flat하게 됨.

Ex  $x_1, x_2$  가 연립을 이루면.