

Chapter 3 : Single - Variate Linear Regression without Bias Term.

1-4. Loss and Cost Function 2.

$$\text{Loss : } \mathcal{L}^{(i)}(\theta) = (y^{(i)} - (\theta x^{(i)}))^2$$

Weight of Feature values
in vector


↑
dot product

Degree of $\theta = 2$

→ θ 가 0이 아닌 2차 항

$$\text{Cost : } J(\theta) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\theta x^{(i)}))^2 \quad \text{Degree of } \theta = 2$$

→ 실제값과 예측값 사이 차이들의 제곱의 평균.



$$\hat{y} = \theta_1 x + \theta_0$$

→ Bias Term

선형관계이나 Bias Term이
추가됨.

구미러

$$\begin{aligned} \text{Model : } \hat{y} &= \theta_1 x + \theta_0 \\ \text{Loss : } \mathcal{L}^{(i)} &= (y^{(i)} - \hat{y}^{(i)})^2 \\ \text{Cost : } J &= \frac{1}{n} \sum_{i=1}^n \mathcal{L}^{(i)} \end{aligned} \quad \text{여러 값들}$$

< Model $\hat{y} = \theta_1 x + \theta_0$ 에 대해 Loss 는 >

$$\mathcal{L}^{(i)} = (y^{(i)} - \hat{y}^{(i)})^2 \quad \hat{y} = \theta_1 x + \theta_0$$

$$\mathcal{L}^{(i)}(\theta_1, \theta_0) = (\underbrace{y^{(i)}}_{\text{Constant}} - (\underbrace{\theta_1}_{\text{Constant}} x^{(i)} + \underbrace{\theta_0}_{\text{Constant}}))^2$$

이때, $\vec{\theta} = \begin{pmatrix} \theta_1 \\ \theta_0 \end{pmatrix}$ $\vec{x}^{(i)} = \begin{pmatrix} x^{(i)} \\ 1 \end{pmatrix}$ 이라고 하면

$$\mathcal{L}^{(i)}(\theta_1, \theta_0) = (y^{(i)} - \underbrace{(\vec{\theta}^T \cdot \vec{x}^{(i)})}_{\text{}}))^2 \quad \text{가 된다}$$

$$[\theta_1 \quad \theta_0] \cdot \begin{bmatrix} x^{(i)} \\ 1 \end{bmatrix} = \theta_1 x^{(i)} + \theta_0$$

< Model $\hat{y} = \theta_1 x + \theta_0$ 에 대한 Cost 는 >

$$J = \frac{1}{n} \sum_{i=1}^n \mathcal{L}^{(i)}$$

$$J(\theta_1, \theta_0) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\theta_1 x^{(i)} + \theta_0))^2$$

4점씩

위와 같은 이유로.

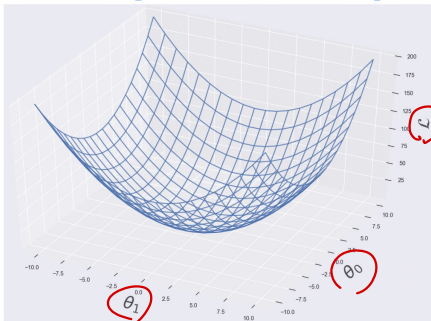
$$J(\theta_1, \theta_0) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\vec{\theta}^T \vec{x}^{(i)}))^2$$

위에서 구한 식

$$\begin{cases} \mathcal{L}^{(i)}(\theta_1, \theta_0) = (y^{(i)} - (\theta_1 x^{(i)} + \theta_0))^2 \\ J(\theta_1, \theta_0) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - (\theta_1 x^{(i)} + \theta_0))^2 \end{cases}$$

둘 다 각각 θ_1 이나 θ_0 에 대해서 2차함수임
 2개인 θ_1 와 θ_0 의 계수 각각 양수이므로 그래프는 U.


Cost function을
 3D로 보면...



gradient로
 가장 빠른 점으로 가야 함.

위의 3개의 factor, 즉 개인 정보 (ex) ^{이름, 나이, 성별} Commuting time & Study hour 등의 데이터를 사용하여 모델을 만드는 것.

< Feature 두개 일때 그래프 >



Linear Model : $y = \theta_2 x_2 + \theta_1 x_1 + \theta_0$

$$L^{(i)} = (y^{(i)} - \hat{y}^{(i)})^2$$

이것이 feature 인스턴스 같다.

$$J = \frac{1}{n} \sum_{i=1}^n L^{(i)}$$

< Feature 가 두개 일 때 Loss or Cost 는 ... >

$$\text{Loss: } L^{(i)}(\theta_2, \theta_1, \theta_0) = (y^{(i)} - (\theta_2 x_2^{(i)} + \theta_1 x_1^{(i)} + \theta_0))^2$$

$$L^{(i)}(\vec{\theta}) = (y^{(i)} - (\vec{\theta}^T \cdot \vec{X}^{(i)}))^2$$

$$\text{Cost: } J(\vec{\theta}) = \frac{1}{n} \sum_{i=1}^n L^{(i)}(\vec{\theta})$$

이때는 Loss or Cost 모두 각각 Weight, $\theta_1, \theta_2, \theta_0$ 여 러개서 2차 함수이다. (U shape)


* 변수 개수 \rightarrow 4차원이라 U 보임 (약 2차)

여기 관련된 loss or cost는 feature의 개수 상관없이.


$$\vec{\theta} = \begin{pmatrix} \theta_n \\ \theta_{n+1} \\ \vdots \\ \theta_1 \\ \theta_0 \end{pmatrix} \quad \vec{x} = \begin{pmatrix} x_n \\ x_{n+1} \\ \vdots \\ x_1 \\ x_0 \end{pmatrix} \quad \text{따라서,}$$

$$\underline{L^{(i)}(\vec{\theta}) = (y^{(i)} - \vec{\theta}^T \vec{x}^{(i)})^2} \quad \underline{J(\vec{\theta}) = \frac{1}{2} \sum_{i=1}^n L^{(i)}(\vec{\theta})} \quad \text{이름.}$$

Loss/Cost Function with Contour Plot




Contour Plot의 최적화 진행 정도를 더 쉽게 관찰.



각 점은 Cost 값이 위치함.

| Real Loss/Cost Functions



실제 Cost function은 x_1, x_2 에 같은 term도 가질 수 있고
그 때부터 x_1, x_2 가 커질수록 평면은 점점 flat하게 됨.
즉 x_1, x_2 가 연립을 이루는 것.